IT INTERN - AI ENGINEERING / 오서연

문서를 읽는 LLM이 틀렸을 때, 어디서 틀렸는지 찾아 고칩니다.

금융 문서를 다루는 LLM 기능을 설계하고, 검색, 검증, API, 배포 과정의 오류를 추적해 개선해 왔습니다.

osy.seoyeon5@gmail.com sohds.github.io/bmwfs github.com/sohds

대표 경험 세 가지

한국산업은행 3쪽

여신 문서 LLM 기능

KDB GPT 정식 배포

회장 보고에서 팀 사례로 소개

기능 제안, 시스템 프롬프트 설계와 테스트를 맡았습니다. 서비스 반영과 배포는 담당자가 진행했습니다.

MIRAE ASSET 미래에셋증권 2쪽

연금 AI Agent

정답 92위 → 1위

이후 재검증한 질문 1건의 BM25 순위

문서 파싱, 청킹, RAG, 검증, 배포까지 기술 설계와 구현을 총괄했습니다.

이화여자대학교 EWHA WOMANS UNIVERSITY 4쪽

대화 엔진 QA와 데이터

속성 결측률 68% → 17%

QA 정답률 +30%p(100문항 정성평가)

QA 모듈, 추천 모듈, 통합 API를 맡았습니다. 결과물은 협력사 서비스에 반영됐고, 세 모듈은 FastAPI로 통합했습니다.

공고의 업무와 이 문서의 근거

담당 업무	내 경험	쪽
LLM 문서 처리의 프롬프트 설계, 성능 개선, 문제 해결	RM과 CO 프롬프트 분리, 앵커 청킹, 답변 숫자 검증	2, 3
vLLM 기반 Self-hosted LLM 서비스 개선	기존 vLLM 지표를 사용 목적별로 재집계한 대시보드 제안	3
Python과 FastAPI 백엔드 개발	세 모듈을 잇는 통합 API, 의도별 라우팅, /chat 엔드포인트	4
클라우드 환경의 AI 애플리케이션 배포	Docker와 Nginx로 클라우드 서버 배포, 재부팅 후 복구 확인	4

오류를 만나면 보는 순서

1

실패한 결과를 직접 엽니다

점수보다 틀린 응답과 검색 순위를 먼저 읽습니다.

2

구조에서 원인을 좁힙니다

프롬프트, 입력 문서, 검색 단위, 지표를 나눠 봅니다.

3

같은 입력으로 다시 잽니다

고친 뒤 재실행하고, 결함은 회귀 검사로 남깁니다.

학력 서울여자대학교 미래산업융합대학 데이터사이언스학과, 2027.02 졸업 예정, 4.11 / 4.5

어학과 자격 OPIc IH, SQLD, ADsP

답이 92위로 밀린 이유를 청킹에서 찾았습니다

미래에셋증권 AI Festival, 2026.07~2026.09, 3인 팀, 기술 설계와 구현 총괄. PDF, DOCX, XLSX, PPTX 문서 58건을 형식별로 파싱하고 PyMuPDF와 Docling을 비교해 제목과 표가 보존되는 결과를 골랐습니다.

관찰

중도인출 질문에서 답이 계속 비었습니다. 시스템 프롬프트를 고쳐도 같은 증상이 반복됐습니다.

원인

검색 결과를 순위대로 열어 보니 질문과 답이 다른 청크로 갈려 있었습니다.

선택

LLM은 분할 앵커와 사유만 반환하고, 본문은 코드가 원문에서 추출하게 바꿨습니다.

확인

금융 분야 팀원이 경계를 검수하고, 같은 질문과 평가셋으로 다시 쟀습니다.

변경 전 / 길이와 제목 기준 청킹

질문: IRP도 중도인출이 가능한가요

1위	doc14#73	일정 조건을 충족하면 가능합니다. [표] IRP 중도인출 사유	답 없음
2위	doc14#68	■질문 리스트	목차
92위	doc14#74	무주택자 주택구입, 임차보증금, 6개월 요양, 재난 …	진짜 답

#74 조건 목록에 질문의 맥락이 빠져 있어, 검색 설정 조정보다 질문과 조건을 같은 청크에 보존하는 작업을 우선했습니다.

변경 후 / 앵커 청킹

같은 질문, BM25 1위

doc14#4 IRP 중도인출 가능 사유

개인형 퇴직연금제도(IRP)도 중도인출이 가능한가요?
일정 조건을 충족하면 중도인출이 가능합니다.
1. 무주택자인 가입자가 본인 명의로 주택을 구입하는 경우
2. 무주택자인 가입자가 주거를 목적으로 임차보증금을 부담하는 경우
… 사유 7개

질문과 조건 목록을 고객 질문 하나에 답할 수 있는 단위로 묶었습니다.

공모전이 끝난 뒤 저장된 두 인덱스로 재검증한 질문 1건의 BM25 단독 순위입니다. 검색 설정과 질의는 동일하며, 파싱본과 청크 구성이 다른 두 인덱스를 비교했습니다(410개, 358개). 청킹 변경만의 효과로 볼 수 없고, 전체 성능인 Hit@5와도 다른 값입니다.

표본 비교

	기존 규칙	앵커 청킹
원문 16건, 52,301자	11,453자(21.9%) 설명 없이 사라짐	2,328자(4.5%) 사유를 남기고 제외
BM25 top-5, 질문 8개	5/8	7/8

질문 8개는 정식 평가셋이 아닙니다.



직접 만든 검수 화면 공개용 가상 데이터입니다.
1 AI가 여기서 자른 이유
2 금융 분야 팀원의 판정
3 판정 근거 메모

숫자 검증에서 찾은 결함

근거의 7억을 모델이 700,000,000으로 쓰면 근거에 없는 숫자로 반려됐습니다. 제가 짠 단위 변환은 0.7억을 7억으로, 7억 5천만을 7억으로 읽었습니다. 기존 토크나이저 규칙으로 통일하고 금액 표기 9종을 회귀 검사로 고정했습니다.

```
t("'0.7억' → 70000000 로도 찾힌다", "70000000" in
expand_units(flat("0.7억")))
t("★ 0.7억을 7억으로 부풀리지 않는다", "700000000" not in
expand_units(flat("0.7억")))
```

계산 문항의 오반려

표본 100건의 숫자 검증 반려 4회가 모두 계산 문항이었습니다. 검증을 완화하지 않고 산식을 Python 계산으로 분리해 입력값과 적용 규칙을 근거에 넣었고, 같은 표본에서 반려는 0회가 됐습니다.

규모
문서 58건, 청크 358개
펀드 데이터 100건

검색 품질
근거 문서 Hit@5 93.8%
팀 평가셋 438문항 중 채점 419문항. 답변 정확도가 아닙니다

실행 안정성
요청 459건 실패 0건
전체 API 경로, 계산 모듈 최종 수정 전 기록

같은 서류는 역할별로, 서버 지표는 용도별로 나눴습니다

AI디지털전략부 인턴, 2026.06~2026.08. 행내 LLM 서비스 KDB GPT의 기능 설계(AI개발팀)와 전결권 규정 PoC(AI데이터팀)를 맡았습니다.

여신승인신청서 종합의견 기능

회장 보고에서 팀 사례로 소개되고, KDB GPT에 정식 배포됐습니다.

KDB GPT에 넣을 기능을 제안하는 과제에서, 참고 문서 가운데 재무와 사업과 리스크 분석을 모아 승인 판단을 정리하는 종합의견을 골랐습니다. 여신 교재 6권과 작성 가이드라인을 읽어 보니 같은 서류를 두 역할이 다르게 쓰고 있었습니다.

	RM(고객전담위원)	CO(심사전문위원)
쓰는 목적	지원 타당성을 설득	리스크가 수용 가능한지 검증
서술 흐름	기업 연혁 → 산업 → 실적 → 재무 → 본건 필요성 → 결론	경쟁력 → 리스크 검토와 관리 방안 → 타당성 → 최종 판단
제안한 보조 방향	CO가 제기할 리스크 질문을 미리 예상	종합의견 검증과 보완 조건 제안

테스트와 검토

테스트케이스로 프롬프트를 조정한 뒤 지점 실무진의 검토를 받았습니다. 문서상 작성 방식과 현장 관행의 차이를 확인했고, 서술 형식과 재무제표 기준이 보완된 최종본이 배포됐습니다.

담당 범위

업무 분석, 기능 제안, 시스템 프롬프트 설계와 실행 검토까지가 제 몫입니다. 서비스 소스코드와 서버 권한은 없었고, 서비스 반영과 배포는 담당자가 진행했습니다.

사용 목적별 LLM 서빙 대시보드

서버 과부하 사례를 계기로, 서버 단위 지표만으로는 부하가 어느 용도에서 왔는지 답할 수 없다는 점을 확인했습니다. 새 지표를 수집하지 않고 기존 vLLM 지표를 사용 목적 네 가지로 재집계한 Grafana 대시보드를 직접 만들어 제안했습니다.

서버 단위로 답하지 못한 질문

- 트래픽이 어떤 업무 용도에서 늘었는가
- 호출이 늘었나, 요청 한 건의 토큰이 길어졌나
- 용도별 증가가 체감 지연으로 이어졌나

보이게 한 것

- 일반 서비스, 검색 기능, 타 팀 API, 메신저 API별 집계
- 토큰과 요청 처리량, 서버별 동시 실행 요청
- TTFT, TPOT, E2E latency의 p95

```
sum by (purpose) (increase(vllm:prompt_tokens_total[$__range])
                + increase(vllm:generation_tokens_total[$__range]))
```

누적값인 Counter는 increase()로 기간 사용량을 구하고, 현재값인 Gauge에는 rate를 쓰지 않았습니다. 개선 효과 수치는 없습니다. 지표는 원인을 좁히는 단서이고, 처음 부하의 원인을 확정한 것은 아닙니다.

전결권 규정 LLM Wiki PoC

규정 원문을 프롬프트로 읽히면 표 안의 표가 무너져 조건과 결재권자의 대응이 끊겼습니다. 규칙 단위로 나누고 원문 위치를 붙이는 구조를 제안해 가상 규정으로 모델 4개를 비교했고, 이 구조가 팀 추진 방향으로 채택됐습니다. 이후 도입은 보류됐습니다.

모델을 API로 묶고, 서버에서 다시 살아나는지 확인했습니다

서로 다른 두 프로젝트입니다. FastAPI는 연구실 과제에서, Docker 배포는 공모전에서 했습니다.

고객의 실시간 쇼핑 상태를 반영하는 가상 휴먼 대화 엔진 개발 / 정보경영연구실, 2024.04~2024.10, 4인 팀

/chat 요청 → LLM API로 Intent, Entity 추출 → **의도별 라우팅** → QA, Recommend, Casual Talk 모듈 → 응답

```
"A 상품의 가격을 알려주세요."
{ "Intent": "QA", "Entity": "A 상품, 가격" }
→ QA 모듈에 원래 질문과 함께 전달
```

구조 설명용 예시이고 실제 로그가 아닙니다.

실패에서 시작한 구조

가격을 물으면 환불 규정을 답하던 QA에 상품명, 의도, 속성을 나눠 검색하는 단계를 더했습니다. 직접 작성한 100문항을 연구실 구성원 5명이 정오로 판정한 정성평가에서 정답률이 개선 전보다 30%p 높아졌습니다.

구현 범위

FastAPI로 세 모듈을 통합하고, 의도 분류 결과로 모듈을 고르는 라우팅과 /chat 엔드포인트를 직접 구현했습니다. Intent는 처리할 모듈을 정하고, Entity는 질문 대상을 전달합니다.

데이터 품질

상세페이지의 글과 이미지에서 비어 있는 속성을 LLM, VLM, ViT로 추출해 전체 상품 속성의 결측률을 68%에서 17%로 낮췄습니다. 결과물은 협력사 서비스에 반영됐습니다.

연금 AI Agent 서버 배포 / NCP Ubuntu, Docker, Nginx

외부 HTTP 80 → Nginx → 127.0.0.1:8080 → **Docker 컨테이너** → Python HTTP API

구성

SSH로 코드를 옮겨 이미지를 빌드하고, 앱 포트를 로컬로 묶어 외부 요청은 Nginx가 받게 했습니다. .env는 읽기 전용으로 마운트하고 로그는 호스트에 남겼습니다.

확인

재시작 정책과 부팅 자동 시작을 설정한 뒤 서버를 재부팅해 /health가 다시 응답하는지 점검했습니다. 이 서버는 FastAPI가 아니라 Python 표준 HTTP 서버입니다.

그 밖의 프로젝트와 연구

멀티에이전트 주식 시황 브리핑
BITAmin 팀 프로젝트, PM, 2026.03~2026.07. FIN:NECT 챌린지 서울 지역예선 참가

온라인 셀러 AI 글쓰기 서비스
연구실 단독 개발, 2024.08~2024.10. 상용 서비스 적용

패션 상세페이지 이미지 생성
연구실 산학 과제, 2025.05~2025.08. 이미지 생성 트랙 담당, 정량 지표 검토와 LLM 평가 루브릭 설계

논문
대한전자공학회 추계학술대회 2024 제1저자, 한국HCI학회 학술대회 2025 공동저자